Clasificación Binaria

Estudiantes de Portugués

Sergio Del Castillo Baranda

4/10/2020

Carga de los datos y librerías

```
students.csv <- file.path(getwd(), 'student-por.csv')</pre>
STUDENTS <- read.csv2(file = students.csv, header = TRUE, sep = ';')
summary(STUDENTS)
##
    school
             sex
                           age
                                       address famsize
                                                          Pstatus
    GP:423
             F:383
                            :15.00
                                       R:197
                                               GT3:457
                                                          A: 80
                      Min.
    MS:226
             M:266
##
                      1st Qu.:16.00
                                       U:452
                                               LE3:192
                                                          T:569
##
                      Median :17.00
##
                      Mean
                             :16.74
##
                      3rd Qu.:18.00
##
                      Max.
                             :22.00
##
                                                            Fjob
         Medu
                          Fedu
                                            Mjob
    Min.
           :0.000
                            :0.000
                                      at_home :135
                                                      at_home: 42
                     Min.
    1st Qu.:2.000
                     1st Qu.:1.000
                                      health: 48
                                                      health: 23
##
##
    Median :2.000
                     Median :2.000
                                      other
                                              :258
                                                      other
##
   Mean
           :2.515
                     Mean
                            :2.307
                                      services:136
                                                      services:181
    3rd Qu.:4.000
                     3rd Qu.:3.000
                                      teacher: 72
                                                      teacher: 36
##
           :4.000
                            :4.000
    Max.
                     Max.
                        guardian
                                                       studytime
##
           reason
                                      traveltime
##
    course
               :285
                      father:153
                                    Min.
                                           :1.000
                                                     Min.
                                                            :1.000
##
    home
               :149
                      mother:455
                                    1st Qu.:1.000
                                                     1st Qu.:1.000
               : 72
                      other: 41
                                    Median :1.000
                                                     Median :2.000
##
    other
##
    reputation:143
                                    Mean
                                           :1.569
                                                     Mean
                                                            :1.931
##
                                    3rd Qu.:2.000
                                                     3rd Qu.:2.000
##
                                           :4.000
                                                            :4.000
                                    Max.
                                                     Max.
##
       failures
                      schoolsup famsup
                                            paid
                                                      activities nursery
##
    Min.
           :0.0000
                      no:581
                                no:251
                                           no:610
                                                      no:334
                                                                 no:128
    1st Qu.:0.0000
                      yes: 68
                                yes:398
                                           yes: 39
                                                      yes:315
                                                                 yes:521
    Median :0.0000
##
##
    Mean
           :0.2219
##
    3rd Qu.:0.0000
    Max.
           :3.0000
##
    higher
                         romantic
                                        famrel
                                                        freetime
              internet
    no: 69
                         no:410
                                                            :1.00
              no:151
                                    Min.
                                           :1.000
##
    yes:580
                         yes:239
                                    1st Qu.:4.000
                                                     1st Qu.:3.00
              yes:498
##
                                    Median :4.000
                                                     Median:3.00
##
                                    Mean
                                           :3.931
                                                     Mean
                                                            :3.18
```

```
##
                                    3rd Qu.:5.000
                                                     3rd Qu.:4.00
##
                                            :5.000
                                    Max.
                                                     Max.
                                                             :5.00
        goout
##
                          Dalc
                                            Walc
                                                           health
                             :1.000
                                              :1.00
                                                              :1.000
##
    Min.
            :1.000
                     Min.
                                      Min.
                                                      Min.
##
    1st Qu.:2.000
                     1st Qu.:1.000
                                      1st Qu.:1.00
                                                      1st Qu.:2.000
    Median :3.000
                     Median :1.000
                                      Median :2.00
                                                      Median :4.000
##
##
    Mean
           :3.185
                     Mean
                            :1.502
                                      Mean
                                              :2.28
                                                      Mean
                                                              :3.536
                     3rd Qu.:2.000
##
    3rd Qu.:4.000
                                      3rd Qu.:3.00
                                                      3rd Qu.:5.000
##
    Max.
            :5.000
                     Max.
                             :5.000
                                      Max.
                                              :5.00
                                                      Max.
                                                              :5.000
                                                              GЗ
##
       absences
                             G1
                                             G2
##
    Min.
           : 0.000
                      Min.
                              : 0.0
                                      Min.
                                              : 0.00
                                                       Min.
                                                               : 0.00
    1st Qu.: 0.000
                      1st Qu.:10.0
                                      1st Qu.:10.00
                                                       1st Qu.:10.00
##
##
    Median : 2.000
                      Median:11.0
                                      Median :11.00
                                                       Median :12.00
                                      Mean
                                                       Mean
##
    Mean
           : 3.659
                      Mean
                              :11.4
                                              :11.57
                                                               :11.91
##
    3rd Qu.: 6.000
                      3rd Qu.:13.0
                                      3rd Qu.:13.00
                                                       3rd Qu.:14.00
##
    Max.
            :32.000
                      Max.
                              :19.0
                                      Max.
                                              :19.00
                                                       Max.
                                                               :19.00
```

a) Se deben realizar pruebas suficientes para obtener una buena selección de variables, obteniendo uno o varios conjuntos de variables tentativos

En primer lugar voy a separar en dos variables el conjunto de columnas del dataset que son categóricas y las que son continuas. A continuación tendremos que realizar la estandarización únicamente de las continuas.

Em este apartado seleccionamos la variable objetivo

```
continuas <- dput(names(select_if(STUDENTS[,-21], is.integer)))
categoricas <- dput(names(select_if(STUDENTS[,-21], is.factor)))

vardep <- "higher"
higher <- STUDENTS[,vardep]

cat("Variables continuas: ",continuas, "\nVariables categoricas: ",categoricas,"\nNuestra variable objections.")</pre>
```

Eliminar las observaciones con missing en alguna variable

```
STUDENTS<-na.omit(STUDENTS,(!is.na(STUDENTS)))
```

SEGUIR ejemplo clase pima. R buscando means y sds en otros R para saber que hacer en ese apartado